



درک و توصیف داده‌ها - قسمت دوم

به پیوست مجموعه داده‌های زیر برای حل تمرین ایفاد گردید.

1. A Clinical Breast Cancer Dataset

2. The Salaries of year 2015

۱. برای هر یک از مجموعه داده‌های فوق، معیارهای تعیین شده مرکزیت داده و شاخص‌های آماری مورد نیاز را محاسبه کنید و در صورت نیاز تفسیری از نتایج بدست آمده، ارائه دهید. ویژگی‌های هر مجموعه داده به شرح زیر است:

Dataset # 1

- Complete TCGA ID
- Gender
- Age at Initial Pathologic Diagnosis : Mean, Mode, Median
- ER Status
- PR Status
- HER2 Final Status
- Tumor : Mode
- Tumor--T1 Coded
- Node: Mode
- Node-Coded
- Metastasis
- Metastasis-Coded
- AJCC Stage: Mode
- Vital Status

Dataset # 2

- Employee Name
- Job Title: Mode
- Base Pay: Mean, Mode, Median
- Overtime Pay: Mean, Mode, Median, a horizontal boxplot of the Overtime Pay
- Other Pay: Mean, Mode, Median
- Benefits: Mean, Mode, Median, a horizontal boxplot of the Benefits
- Total Pay: Mean, Mode, Median
- Total Pay & Benefits
- Year

۲. برای مجموعه داده شماره ۱، Boxplot از ویژگی‌های Age و Tumor، و Boxplot از ویژگی‌های Age و AJCC Stage را با استفاده از پایتون رسم نمایید.



۳. برای مجموعه داده شماره ۲، چند Boxplot از ویژگی‌های Job Title و سایر ویژگی‌ها رسم کنید. انتخاب نوع شغل و ویژگی‌های دیگر اختیاری است (مثلاً می‌توانید Boxplot حقوق پایه افرادی که در عنوان شغل آن‌ها عبارت ASSOCIATE TAX AUDITOR است را با PHYSICIAN AND SURGEON مقایسه کنید).
۴. برای مجموعه داده شماره ۱ و ۲ بصورت جداگانه تمامی مراحل محاسبه Dissimilarity بین دو نمونه را بصورت دستی بنویسید.

مهلت تحویل: ۱۴۰۲/۰۲/۲۰

پاسخ تمرین را در قالب یک فایل PDF بصورت یک گزارش فنی (Technical Report) آماده سازید.

می‌توانید از زبان پایتون برای رسم نمودارها و پاسخ به سوالات استفاده نمایید.

اگر تمرین شامل برنامه‌نویسی است ارائه سورس کد برنامه در فایل پیوست الزامی است.

تمامی فایل‌های ارسالی به فرمت rar. و نام فایل‌ها به فرمت زیر باشد که # شماره تمرین شماست:

DM_HW#_YourStudentNumber_Family.rar